

**LAPORAN UTS PENAMBANGAN DATA**  
**“Deteksi Anomali pada Data Pembelian dan Penjualan Obat**  
**Menggunakan Metode Rule Based dan Isolation Forest”**



**Penambangan Data (IF25-32025)**  
**Kelompok-09**

Reynaldi Cristian Simamora (121240116)

Akhwan Adib Al-Hakim (122140149)

**PROGRAM STUDI TEKNIK INFORMATIKA**  
**FAKULTAS TEKNOLOGI INDUSTRI**  
**INSTITUT TEKNOLOGI SUMATERA**  
**2025**

## 1. Pendahuluan

Perkembangan teknologi informasi dan komunikasi pada era digital telah membawa perubahan signifikan terhadap cara data dikumpulkan, disimpan, dan dianalisis. Pertumbuhan pesat pada volume, kecepatan, dan keragaman data (*big data characteristics*) menuntut penerapan metode analisis yang lebih adaptif dan cerdas untuk memperoleh wawasan yang relevan serta mendukung pengambilan keputusan strategis. Dalam konteks ini, *data mining* berperan penting sebagai proses penemuan pengetahuan tersembunyi dari kumpulan data besar melalui penerapan teknik statistik, pembelajaran mesin (*machine learning*), serta kecerdasan buatan (*artificial intelligence*) [1].

Salah satu cabang penting dalam data mining adalah deteksi anomali (*anomaly detection*), yaitu proses mengenali pola data yang menyimpang secara signifikan dari perilaku normal sistem. Deteksi anomali memiliki peran krusial dalam berbagai domain, seperti keamanan jaringan, manufaktur, sistem keuangan, dan distribusi logistik, karena anomali sering kali merepresentasikan kesalahan, gangguan proses, atau bahkan indikasi kecurangan (*fraud*). Menurut Wang *et al.* (2021), penerapan pembelajaran mesin pada deteksi anomali telah berkembang pesat dengan berbagai pendekatan berbasis jaringan saraf, algoritma statistik, serta model pembelajaran tanpa pengawasan (*unsupervised learning*) untuk meningkatkan ketepatan identifikasi pola abnormal pada sistem berskala besar [1].

Dalam konteks industri farmasi, khususnya pada analisis data transaksi penjualan, pembelian, dan stok obat, keberadaan anomali dapat berdampak langsung terhadap efisiensi operasional dan akurasi pencatatan. Setiap transaksi idealnya mengikuti pola yang logis—misalnya jumlah pembelian sesuai kebutuhan stok, harga jual yang stabil, dan pergerakan stok yang konsisten dengan permintaan. Namun, pada praktiknya sering ditemukan data yang menyimpang akibat kesalahan pencatatan, gangguan sistem, maupun aktivitas manipulatif. Bentuk anomali tersebut meliputi nilai stok negatif, transaksi ganda, harga yang tidak sesuai pola historis, atau jumlah pembelian yang ekstrem dibandingkan periode sebelumnya.

Untuk mendeteksi anomali semacam ini, digunakan berbagai metode seperti Isolation Forest, pendekatan berbasis aturan (*rule-based*), serta model pembelajaran mendalam (*deep learning*) yang mampu menganalisis data kompleks dan dinamis. Chen *et al.* (2020)

menunjukkan bahwa algoritma *Isolation Forest* efektif dalam mengidentifikasi produk atau entitas dengan perilaku operasional yang menyimpang, khususnya pada sistem dengan banyak kondisi operasional (*multiple operating conditions*) [4]. Sementara itu, Gowri dan Paramasivan (2016) memperkenalkan teknik *rule-based anomaly detection* yang memanfaatkan aturan adaptif untuk mengidentifikasi perilaku abnormal pada jaringan sensor nirkabel secara efisien [3].

Seiring berkembangnya kompleksitas data modern, pendekatan berbasis graph deep learning juga mulai diterapkan dalam sistem terdistribusi, termasuk pada proses deteksi anomali yang melibatkan hubungan antar entitas atau node data. Pazho *et al.* (2024) menekankan bahwa metode deteksi anomali berbasis *graph neural network (GNN)* mampu meningkatkan akurasi identifikasi pola menyimpang dengan mempertimbangkan konteks hubungan antar objek dalam jaringan data besar [2]. Pendekatan ini berpotensi besar diterapkan pada sistem farmasi modern yang memiliki struktur data transaksional dan relasional kompleks, seperti hubungan antara pemasok, gudang, dan apotek.

Dengan demikian, penerapan metode deteksi anomali dalam analisis dataset transaksi obat tidak hanya berfungsi untuk menemukan kesalahan atau inkonsistensi data, tetapi juga sebagai bagian dari strategi peningkatan data governance, efisiensi operasional, dan keamanan sistem. Melalui penerapan algoritma modern seperti *Isolation Forest* dan *graph-based anomaly detection*, organisasi dapat mendeteksi penyimpangan lebih awal, mencegah kerugian akibat kesalahan logistik, serta memperkuat proses pengambilan keputusan berbasis data yang lebih andal dan adaptif.

## **2. Percobaan Analisa Dataset**

### **A. Tujuan Percobaan**

Percobaan ini bertujuan untuk menganalisis dataset transaksi penjualan, pembelian, dan stok obat guna mendeteksi adanya data yang tidak wajar atau menyimpang dari pola normal. Salah satu pendekatan yang digunakan adalah *Anomaly Detection* atau deteksi anomali, yang berfungsi untuk mengidentifikasi pola perilaku data yang tidak sesuai dengan karakteristik umum sistem transaksi.

## **B. Gambaran Umum Dataset**

Dataset yang digunakan dalam penelitian ini berisi catatan transaksi obat yang mencakup tiga aktivitas utama, yaitu pembelian (barang masuk), penjualan (barang keluar), dan perubahan stok di gudang atau apotek. Setiap entri data memiliki sembilan label utama, yakni KODE (kode unik produk), NAMA PRODUK (nama atau deskripsi obat), UNIT (satuan kemasan seperti STRIP atau BTL), TANGGAL (tanggal transaksi), NO.TRANSAKSI (nomor referensi transaksi), QTY.MSK (jumlah barang masuk), NILAI MSK (nilai pembelian), QTY.KLR (jumlah barang keluar), dan NILAI KLR (nilai penjualan). Struktur dataset menyerupai laporan transaksi manual yang dikelompokkan berdasarkan produk dan periode tertentu, yang umum digunakan dalam sistem administrasi farmasi. Namun, dalam praktiknya sering ditemukan berbagai anomali, seperti nilai stok negatif (QTY.KLR melebihi QTY.MSK), harga jual lebih rendah dari harga beli, kuantitas transaksi ekstrem, nomor transaksi duplikat, tanggal transaksi yang tidak berurutan secara logis, hingga variasi harga yang tidak proporsional antarperiode. Melalui penerapan metode deteksi anomali seperti rule-based filtering dan Isolation Forest, sistem dapat mengenali penyimpangan tersebut secara otomatis untuk memastikan integritas data, mengidentifikasi kesalahan pencatatan, serta mendeteksi potensi kecurangan atau manipulasi dalam proses bisnis apotek maupun distributor obat.

## **C. Tahap Pra-Pemrosesan (Preprocessing)**

Sebelum dilakukan analisis, dataset harus melalui tahap pra-pemrosesan agar dapat diubah menjadi format yang terstruktur dan siap digunakan dalam proses analitik. Tujuan utama tahap ini adalah memastikan bahwa seluruh data memiliki format yang seragam dan bebas dari inkonsistensi, seperti spasi kosong berlebih, pemisah kolom yang tidak standar, atau nilai numerik yang tidak dapat diinterpretasikan secara langsung. Langkah-langkah pra-pemrosesan dilakukan dengan memastikan terlebih dahulu bahwa file input tersedia dan dapat diakses, kemudian dibaca menggunakan modul CSV agar setiap baris data dapat diolah dengan efisien. Setiap baris transaksi dinormalisasi menjadi sembilan kolom tetap yang mencakup informasi utama seperti kode produk, nama obat, tanggal transaksi, nomor transaksi, kuantitas masuk dan keluar, serta nilai pembelian dan penjualan. Data mentah kemudian direkonstruksi kembali ke format teks menyerupai laporan transaksi asli untuk memudahkan proses pencocokan pola

menggunakan ekspresi reguler (regex). Dua pola utama diterapkan untuk mendeteksi header produk dan baris transaksi individu, sementara fungsi *clean\_num()* digunakan untuk menstandarkan format angka agar dapat dikonversi menjadi nilai numerik yang valid. Setiap baris hasil parsing diklasifikasikan menjadi dua kelompok utama, yaitu data transaksi harian dan data total kuantitas per produk. Seluruh hasil akhir disimpan dalam dua DataFrame terpisah, *df\_transaksi* dan *df\_total*, sebelum diekspor ke file CSV, sehingga data siap digunakan untuk analisis lebih lanjut seperti deteksi anomali, evaluasi stok, dan analisis pola transaksi.


#### **D. Penerapan Rule Based dan Isolation Forest**

Pada tahap ini dilakukan penerapan metode deteksi anomali terhadap dataset transaksi pembelian obat (barang masuk) menggunakan kombinasi dua pendekatan utama, yaitu Rule-Based Detection dan Isolation Forest. Tujuannya adalah mengidentifikasi pola transaksi yang tidak wajar akibat kesalahan pencatatan, anomali operasional, atau indikasi kecurangan. Dataset hasil pra-pemrosesan berjumlah 138.352 baris, dengan 15.675 baris transaksi barang masuk sebagai fokus analisis. Kolom numerik seperti *qty\_masuk* dan *nilai\_masuk* dinormalisasi menggunakan *StandardScaler* agar memiliki skala yang seimbang sebelum diproses dengan algoritma *Isolation Forest*.

Metode *Isolation Forest* digunakan karena kemampuannya dalam mengisolasi data menyimpang melalui prinsip *random partitioning*. Parameter *contamination* sebesar 0,05 (5%) ditetapkan untuk memperkirakan proporsi data anomali, dan hasilnya menunjukkan terdapat 784 transaksi yang terindikasi menyimpang berdasarkan distribusi statistik. Sementara itu, pendekatan Rule-Based Detection digunakan untuk mendeteksi anomali berdasarkan ambang batas eksplisit, di mana transaksi dianggap anomali jika: (1) *nilai\_masuk* melebihi Rp10.000.000, (2) *qty\_masuk* berada di atas kuantil 98%, atau (3) *nilai\_masuk* berada di atas kuantil 98% dari seluruh data. Dari hasil tersebut, diperoleh 471 transaksi yang memenuhi kriteria anomali berbasis aturan.

Kedua metode kemudian dikombinasikan untuk menghasilkan klasifikasi akhir, di mana transaksi dianggap anomali final jika terdeteksi oleh keduanya secara bersamaan. Pendekatan ini menghasilkan 460 transaksi anomali final, yang merepresentasikan data paling menyimpang baik secara statistik maupun logis. Visualisasi hasil dalam bentuk *scatter plot* menunjukkan bahwa

anomali cenderung terkonsentrasi pada area dengan nilai transaksi tinggi dan kuantitas pembelian ekstrem, menandakan adanya pola pembelian tidak lazim yang menyimpang dari tren historis. Pendekatan gabungan ini dinilai efektif karena mampu menyeimbangkan sensitivitas model statistik dengan aturan bisnis yang rasional, sehingga hasil deteksi lebih akurat dan relevan secara operasional.



Gambar 1. Visualisasi Deteksi Anomali

Dalam penerapan proses deteksi anomali pada dataset transaksi pembelian obat, pemilihan parameter *contamination* sebesar 0.05 pada metode *Isolation Forest* serta penggunaan ambang batas atas berupa *quantile* 0.98 dan nilai transaksi di atas Rp10.000.000 pada pendekatan *Rule-Based Detection* didasarkan pada pertimbangan statistik yang selaras dengan konteks operasional bisnis farmasi. Parameter *contamination* sebesar 5% dipilih untuk menandai sekitar 5% data yang paling menyimpang dari distribusi umum, dengan asumsi bahwa proporsi data ekstrem atau kesalahan pencatatan dalam sistem transaksi farmasi relatif kecil namun tetap signifikan untuk diawasi. Ambang batas *quantile* 0.98 diterapkan guna mengidentifikasi

transaksi dengan nilai atau kuantitas yang berada di antara 2% tertinggi dari keseluruhan data, sedangkan batas nominal Rp10 juta dipilih karena transaksi dengan nilai di atas angka tersebut secara empiris jarang terjadi dan biasanya merepresentasikan pembelian skala besar atau potensi kesalahan input akibat salah penempatan nilai atau titik desimal.

Berdasarkan hasil penerapan kedua metode tersebut, anomali yang terdeteksi dapat diklasifikasikan menjadi dua kategori utama. Pertama, anomali akibat kesalahan input, yang ditandai dengan ketidakseimbangan antara jumlah (*qty*) dan nilai transaksi (*nilai\_masuk*) sehingga menghasilkan harga satuan yang tidak logis, bahkan berada di bawah satu rupiah. Sebagai contoh, produk *Amoxicillin 500mg* tercatat memiliki kuantitas sebesar 10.000 strip dengan nilai total Rp29.504, yang berarti harga per unit hanya sekitar Rp2,95 — jauh di bawah harga pasaran normal. Fenomena serupa juga ditemukan pada produk *Kana White 30gr* dan *Masker Karet Nian*, yang menunjukkan kemungkinan adanya kesalahan titik desimal atau salah pengisian kolom nilai transaksi. Kedua, anomali transaksi sah bernilai besar, yakni transaksi yang memiliki nilai tinggi namun masih rasional secara ekonomi dan sesuai dengan karakteristik produk. Misalnya, pembelian *Appeton WG Adult Coklat*, *Blackmores Fish Oil*, dan *Minyak Kutus Kutus* menunjukkan nilai transaksi mencapai puluhan juta rupiah, tetapi tetap proporsional jika dihitung berdasarkan harga per unit produk impor premium yang memiliki nilai jual tinggi.

Dengan demikian, penggunaan parameter dan batas nilai tersebut memungkinkan model deteksi anomali untuk membedakan secara efektif antara penyimpangan yang disebabkan oleh kesalahan pencatatan dengan transaksi sah bernilai besar yang valid secara bisnis. Pendekatan ini menekankan bahwa deteksi anomali tidak hanya bergantung pada analisis statistik semata, melainkan juga memperhitungkan *business logic* dan konsistensi harga per unit dalam konteks industri farmasi. Hal ini penting agar sistem deteksi yang diterapkan tidak menghasilkan *false positive* terhadap transaksi normal, namun tetap memiliki sensitivitas yang tinggi terhadap kesalahan input yang dapat berdampak pada akurasi laporan keuangan, manajemen stok, serta keandalan sistem informasi penjualan dan pembelian obat.

### 3. Kesimpulan

Berdasarkan hasil penerapan metode deteksi anomali menggunakan *Isolation Forest* dan *Rule-Based Detection*, dapat disimpulkan bahwa tidak semua data yang teridentifikasi sebagai

anomali merupakan kesalahan. Dalam konteks transaksi pembelian obat, anomali dapat dikategorikan menjadi dua jenis utama.

Pertama, anomali akibat kesalahan input data, yang terjadi karena ketidakkonsistenan antara jumlah (*qty*) dan nilai transaksi (*nilai\_masuk*) sehingga menghasilkan harga per unit tidak wajar, seperti pada produk *Amoxicillin 500mg*, *Kana White 30gr*, dan *Masker Karet Nian*, di mana harga tercatat jauh di bawah nilai pasar. Hal ini biasanya disebabkan oleh kesalahan teknis seperti penggunaan tanda desimal atau kolom entri yang keliru, dan perlu segera diperbaiki agar tidak mengganggu akurasi laporan stok maupun nilai pembelian.

Kedua, transaksi sah bernilai besar, yaitu transaksi dengan nilai tinggi namun masih rasional secara bisnis. Contohnya terdapat pada produk *Appeton WG Adult Coklat*, *Blackmores Fish Oil*, dan *Minyak Kutus Kutus*, yang memang memiliki harga tinggi karena merupakan produk impor premium. Transaksi seperti ini mencerminkan aktivitas operasional normal dan bukan termasuk kesalahan input, sehingga perlu diperlakukan sebagai transaksi valid bernilai besar.



## Lampiran

- Tautan Github : [Repositori Github](#)
- Tautan Notebook : [Notebook IPYNB](#)
- Tautan Youtube : [Video Penjelasan](#)
- Tautan Dataset : <https://s.itera.id/Dataset-UTS>

## Referensi

- [1] S. Wang, J. F. Balarezo, S. Kandeepan, A. Al-Hourani, K. G. Chavez and B. Rubinstein, "Machine Learning in Network Anomaly Detection: A Survey," in *IEEE Access*, vol. 9, pp. 152379-152396, 2021, doi: 10.1109/ACCESS.2021.3126834
- [2] A. D. Pazho, G. A. Noghre, A. A. Purkayastha, J. Vempati, O. Martin and H. Tabkhi, "A Survey of Graph-Based Deep Learning for Anomaly Detection in Distributed Systems," in *IEEE Transactions on Knowledge and Data Engineering*, vol. 36, no. 1, pp. 1-20, Jan. 2024, doi: 10.1109/TKDE.2023.3282898
- [3] M. Gowri and B. Paramasivan, "Rule-Based Anomaly Detection Technique Using Roaming Honeypots for Wireless Sensor Networks," *ETRI Journal*, vol. 38, no. 6, pp. 1145–1152, Dec. 2016, doi: <https://doi.org/10.4218/etrij.16.0115.0795>.
- [4] H. Chen, H. Ma, X. Chu, and D. Xue, "Anomaly detection and critical attributes identification for products with multiple operating conditions based on isolation forest," *Advanced Engineering Informatics*, vol. 46, p. 101139, Oct. 2020, doi: <https://doi.org/10.1016/j.aei.2020.101139>.